

机器视觉基础

孙明竹

sunmz@nankai.edu.cn



机器人与信息自动化研究所

Institute of Robotics & Automatic Information System



南开大学


Nankai University

第二部分 图像处理基础

Image Processing


概述：特征检测与物体检测

➤ *What objects are where?*



Zou Z , Shi Z , Guo Y , et al. Object Detection in 20 Years: A Survey[J]. 2019.

概述：特征检测与物体检测



Zou Z , Shi Z , Guo Y , et al. Object Detection in 20 Years: A Survey[J]. 2019.


主要内容

- 第2章 数字图像的概念与性质
- 第3章 图像预处理
- 第4章 二值图像处理
- 第5章 传统特征检测
 - 5.1 角点检测 (5.3.10节)
 - 5.2 SIFT特征检测与匹配 (10.2节)
 - 5.3 HOG特征与行人检测 (10.6.3节)
 - 5.4 基于Hough变换的线检测与圆检测 (6.2.6节)
 - 5.5 图像特征检测在生物、显微视觉中的应用

5.1.1 角点检测概述

➤ 角点(Corner Point)的定义


- 角点是在邻域内的各个方向上灰度变化值足够高的点
- 角点是图像边缘曲线上曲率极大值的点
- 别名：兴趣点、关键点(Key point)、特征点(Feature point)




角点检测的准则

1

角点检测的
正确性



检测出所有真正的角点



不检测出错误的角点


角点检测的准则

1

角点检测的
正确性

2

角点定位的
准确性



检测出的角点位置准确

角点检测的准则



1


角点检测的
正确性

2


角点定位的
准确性

3

角点检测算法
稳定性与效率




算法具有较高的稳定性



算法受噪声影响较小

角点检测方法

➤ 一些早期的角点检测方法



角点检测方法分类

➤ 基于灰度图像的角点检测

- 基于梯度的方法：通过计算边缘的曲率判断角点
- 基于模板的方法：考虑像素邻域点的灰度变化, 将与邻点亮度对比足够大的点定义为角点
- 基于模板梯度组合的方法

➤ 基于二值图像的角点检测

- 将二值图像作为单独的检测目标, 可使用各种基于灰度图像的角点检测方法

➤ 基于轮廓曲线的角点检测


- 通过角点强度或曲线曲率提取角点

角点检测步骤

- 1) 使用角点检测算子，对图像的每个像素计算角点响应函数(Corner Response Function)
- 2) 阈值化角点响应函数，根据实际情况选择阈值
- 3) 对阈值化的角点响应函数进行非极大值抑制，并获取非零点作为角点



原始图像



角点响应函数



阈值化





角点检测结果



角点检测的基本思想

- 通过一个小的滑动窗口在邻域检测角点
- 在任意方向上移动窗口，若窗口内的灰度值都有剧烈的变化，则窗口的中心就是角点



平滑区域



边缘




角点




5.1.2 Moravec角点检测

- 在任意方向上移动窗口，若窗口内的灰度值都有剧烈的变化，则窗口的中心就是角点





5.1.2 Moravec角点检测

- 在任意方向上移动窗口，若窗口内的灰度值都有剧烈的变化，则窗口的中心就是角点



$$E(\Delta x, \Delta y) = \sum_{x_i, y_i} w(x_i, y_i) [I(x_i, y_i) - I(x_i + \Delta x, y_i + \Delta y)]^2$$

- 窗口函数 w : 二值函数
- 偏移量 $(\Delta x, \Delta y)$ 取值为 $(1, 0), (1, 1), (0, 1), (-1, 1)$
- 角点响应函数: $R = \min\{E\}$



Moravec角点检测算法

算法： Moravec角点检测

1. 对于原始图像，取偏移量 $(\Delta x, \Delta y)$ 为 $(1,0), (1,1), (0,1), (-1,1)$ ，分别计算每一像素点 (x_i, y_i) 的灰度变化

$$E(\Delta x, \Delta y) = \sum_{x_i, y_i} w(x_i, y_i) [I(x_i, y_i) - I(x_i + \Delta x, y_i + \Delta y)]^2$$

2. 对于每一像素点 (x_i, y_i) ，计算角点响应函数 $R(x_i, y_i) = \min\{E\}$
3. 设定阈值 T ，将角点响应函数 $R(x_i, y_i)$ 中低于 T 的值设为0
4. 在窗口范围内进行非极大值抑制：遍历角点响应函数，若某个像素的角点响应函数在窗口内不是最大，该像素置0
5. 选择非零点作为角点检测结果

Moravec角点检测结果





➤ 原始图像




Moravec角点检测结果




➤ 角点响应函数



Moravec角点检测结果



➤ 阈值化





Moravec角点检测结果

- 非极大值抑制，得到角点检测结果



Moravec角点检测分析


- 二值的窗口函数导致角点响应函数不够光滑
- 只在四个方向上计算灰度值变化，导致角点响应函数在多处都有较大响应
- 对于每个点只考虑 E 的最小值，导致算法对边缘有很强的反应



5.1.3 Harris角点检测

➤ Moravec角点检测的问题


- 窗口函数是二值函数



- 只在四个方向上计算灰度值变化
- 对于每个点只考虑 E 的最小值

➤ Harris角点检测对问题的改进

- 使用高斯函数作为窗口函数



- 通过泰勒级数展开考察所有小的移动
- 定义新的角点响应函数以降低边缘响应

Harris C, Stephens M. **A combined corner and edge detector**. Alvey vision conference. 1988, 15: 50.

通过 E 考察所有小的移动

$$E(\Delta x, \Delta y) = \sum_{x_i, y_i} w(x_i, y_i) [I(x_i + \Delta x, y_i + \Delta y) - I(x_i, y_i)]^2$$

- 将 E 在 (x_i, y_i) 处进行泰勒级数展开，得到：

$$E(\Delta x, \Delta y) \approx [\Delta x \quad \Delta y] M \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix}$$


- M 是 2×2 的实对称矩阵（自相关矩阵）

$$M = \begin{bmatrix} A & C \\ C & B \end{bmatrix} \quad \begin{aligned} A &= \sum_w (I_x(x_i, y_i))^2 \\ B &= \sum_w (I_y(x_i, y_i))^2 \\ C &= \sum_w I_x(x_i, y_i) I_y(x_i, y_i) \end{aligned}$$

利用 M 定义新的角点响应函数

- 自相关矩阵 M 描述了图像局部区域的灰度变化趋势


$$M = \begin{bmatrix} A & C \\ C & B \end{bmatrix}$$



- M 的特征值 λ_1, λ_2 确定椭圆的形状，特征向量确定椭圆的方向
- 可通过分析 λ_1, λ_2 判定灰度在各方向上的变化情况

利用 M 定义新的角点响应函数

定性分析：基于
M特征值 λ_1, λ_2
的图像点分类



利用 M 定义新的角点响应函数

定量分析：定义
角点响应函数


角点响应函数

$$R = \det(M) - k(\text{trace}(M))^2$$

$$\det(M) = \lambda_1 \lambda_2 = AB - C^2$$

$$\text{trace}(M) = \lambda_1 + \lambda_2 = A + B$$

经验常数 $k = 0.04 \sim 0.06$



5.1.3 Harris角点检测

算法：Harris角点检测

1. 对于图像上的每一个点 (x_i, y_i) ，计算自相关矩阵M

$$M = \begin{bmatrix} A & C \\ C & B \end{bmatrix}$$
$$A = \sum_w (I_x(x_i, y_i))^2$$
$$B = \sum_w (I_y(x_i, y_i))^2$$
$$C = \sum_w I_x(x_i, y_i) I_y(x_i, y_i)$$

2. 对于每一像素点 (x_i, y_i) 计算角点响应函数 $R(x_i, y_i)$

$$R(x_i, y_i) = \det(M) - k (\text{trace}(M))^2$$

$$\det(M) = \lambda_1 \lambda_2 = AB - C^2$$

$$\text{trace}(M) = \lambda_1 + \lambda_2 = A + B$$

5.1.3 Harris角点检测

算法：Harris角点检测（续）

3. 设定阈值 T ，将角点响应函数 $R(x_i, y_i)$ 中所有低于 T 的值设为0
4. 在窗口范围 r 内进行非极大值抑制：遍历角点响应函数，若某个像素的灰度值在窗口内不是最大，该像素置0
5. 选择非零点作为角点检测结果

➤ 算法参数

- 高斯函数参数 σ
- 参数 k
- 阈值 T
- 窗口大小 r



Harris角点检测结果

➤ 原始图像



Harris角点检测结果

➤ 角点响应函数



Harris角点检测结果

➤ 阈值化



Harris角点检测结果

- 非极大值抑制，得到角点检测结果




角点检测

➤ OpenCV3: cornerHarris

- Harris角点检测的基本函数，计算原始图像的角点响应函数
- 后续需要阈值化、非极大值抑制，最终得到角点



原始图像



阈值化的
角点响应函数



角点检测结果

角点检测



- OpenCV3: goodFeaturesToTrack
 - 计算适合跟踪的优质特征，特征分布更均匀



原始图像



Harris角点检测




goodFeatures
角点检测

Shi J, Tomasi C. **Good features to track**. Proceedings CVPR'94, 1994: 593-600.

Harris角点检测讨论(I)


- Harris角点的优点
 - ①计算简单
 - ②提取的点特征均匀且合理
 - ③稳定: Harris算子对图像旋转、亮度变化、噪声影响和视点变换不敏感



Harris角点检测讨论(II)

➤ Harris 算子的局限性

- ①对尺度很敏感，不具有尺度不变性
- ②提取的角点精度是像素级的
- ③需要设计角点匹配算法





5.2.1 SIFT特征检测

➤ SIFT特征检测算法的特点

- SIFT特征是图像的局部特征，对旋转、尺度缩放、亮度变化保持不变性，对视角变化、仿射变换、噪声也保持一定程度的稳定性
- 信息量丰富，适用于在海量特征数据库中进行匹配
- 多量性，少数物体也可以产生大量SIFT特征

➤ SIFT特征检测的步骤

1. 检测尺度空间的极值点
2. 精确定位特征点(Keypoint)
3. 设定特征点的方向参数
4. 生成特征点的描述子（128维向量）

Lowe D G. **Distinctive image features from scale-invariant keypoints**. International journal of computer vision, 2004, 60(2): 91-110.

1) 检测尺度空间的极值点 (I)

➤ 尺度空间

- 通过尺度空间理论模拟图像数据的多尺度特征
- 高斯函数是实现尺度变换的唯一线性核
- 二维图像 $I(x, y)$ 的尺度空间


$$L(x, y, \sigma) = I(x, y) * g(x, y, \sigma) \quad g(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

➤ 高斯差分(DOG)尺度空间

- 用于在尺度空间检测到稳定的关键点

$$\begin{aligned} D(x, y, \sigma) &= [G(x, y, k\sigma) - G(x, y, \sigma)] * I(x, y) \\ &= L(x, y, k\sigma) - L(x, y, \sigma) \end{aligned}$$


高斯尺度空间与差分尺度空间




1) 检测尺度空间的极值点 (II)

➤ 构建高斯金字塔

- 图像金字塔：图像不断降采样
- 高斯金字塔：在图像金字塔中加了高斯滤波，使得每层金字塔有多张高斯模糊图像




高斯卷积图像



first octave


高斯差分图像

...



second octave

...



third octave

...




1) 检测尺度空间的极值点 (III)

➤ 极值点检测

- 在高斯差分尺度空间检测局部极大/极小值
- 检测点与其同尺度的8个相邻点、上下相邻尺度对应的 9×2 个点进行比较, 以确保在尺度空间和二维图像空间都检测到极值点

➤ 极值点的描述

- 金字塔坐标 o (可由 σ 算出)
- 尺度空间坐标 σ
- 二维图像坐标 (x, y)



2) 精确定位特征点 (I)

➤ 精确定位极值点

- 通过采样极值点的三维二次函数，确定其精确位置
- $D(x, y, \sigma)$ 表示 σ 尺度下 (x, y) 点的高斯差分尺度空间值
- 设采样极值点在**原点**， $\mathbf{X} = (x, y, \sigma)^T$ 表示精确定位值，其高斯差分尺度空间值：

$$D(\mathbf{X}) = D + \frac{\partial D^T}{\partial \mathbf{X}} \mathbf{X} + \frac{1}{2} \mathbf{X}^T \frac{\partial^2 D}{\partial \mathbf{X}^2} \mathbf{X}$$

- 令 $D(\mathbf{X})$ 的一阶导数为零，获取精确极值点

$$\frac{\partial D(\mathbf{X})}{\partial \mathbf{X}} = \frac{\partial D}{\partial \mathbf{X}} + \frac{\partial^2 D}{\partial \mathbf{X}^2} \hat{\mathbf{X}} = 0 \quad \hat{\mathbf{X}} = -\frac{\partial^2 D^{-1}}{\partial \mathbf{X}^2} \frac{\partial D}{\partial \mathbf{X}}$$

计算极值点的精确位置

➤ 线性方程求解

$$\hat{\mathbf{X}} = -\frac{\partial^2 D^{-1}}{\partial \mathbf{X}^2} \frac{\partial D}{\partial \mathbf{X}} \quad \longrightarrow \quad \begin{bmatrix} \frac{\partial^2 D}{\partial x^2} & \frac{\partial^2 D}{\partial xy} & \frac{\partial^2 D}{\partial x\sigma} \\ \frac{\partial^2 D}{\partial yx} & \frac{\partial^2 D}{\partial y^2} & \frac{\partial^2 D}{\partial y\sigma} \\ \frac{\partial^2 D}{\partial \sigma x} & \frac{\partial^2 D}{\partial \sigma y} & \frac{\partial^2 D}{\partial \sigma^2} \end{bmatrix} \begin{bmatrix} x \\ y \\ \sigma \end{bmatrix} = -\begin{bmatrix} \frac{\partial D}{\partial x} \\ \frac{\partial D}{\partial y} \\ \frac{\partial D}{\partial \sigma} \end{bmatrix}$$

- 用差分近似偏导数
- 如果X在任何方向上大于0.5，表示极值点更接近另一个采样点，在该点重复计算

2) 精确定位特征点 (II)

➤ 去除不稳定极值点

$$D(\mathbf{X}) = D + \frac{\partial D^T}{\partial \mathbf{X}} \mathbf{X} + \frac{1}{2} \mathbf{X}^T \frac{\partial^2 D}{\partial \mathbf{X}^2} \mathbf{X}$$

$$\hat{\mathbf{X}} = -\frac{\partial^2 D^{-1}}{\partial \mathbf{X}^2} \frac{\partial D}{\partial \mathbf{X}} \quad \longrightarrow \quad D(\hat{\mathbf{X}}) = D + \frac{1}{2} \frac{\partial D^T}{\partial \mathbf{X}} \hat{\mathbf{X}}$$

➤ 抛弃 $|D(\hat{\mathbf{X}})|$ 过小的点:

$$|D(\hat{\mathbf{X}})| < 0.03$$

2) 精确定位特征点 (III)

- 去除边缘响应过大的极值点
 - 通过主曲率分析去除边缘响应过大的极值点
 - 计算差分图像D的Hessian矩阵:

$$\mathbf{H} = \begin{bmatrix} D_{xx} & D_{xy} \\ D_{xy} & D_{yy} \end{bmatrix}$$

- 保留满足如下条件的极值点

$$\frac{\text{trace}(\mathbf{H})^2}{\det(\mathbf{H})} < \frac{(r+1)^2}{r} \quad r = 10$$

233x189



原始图像

832



极值点

729



去除不稳定极值点

536



去除边缘响应过大极值点

3) 设定特征点的方向参数



- 在高斯尺度空间，计算特征点邻域像素的梯度

$$m(x, y) = \sqrt{[L(x+1, y) - L(x-1, y)]^2 + [L(x, y+1) - L(x, y-1)]^2}$$

$$\theta(x, y) = \arctan\{[L(x, y+1) - L(x, y-1)] / [L(x+1, y) - L(x-1, y)]\}$$


- 通过邻域梯度方向直方图确定特征的方向参数

- 梯度方向直方图的范围：[0, 360]
- 特征点的主方向：直方图的峰值
- 特征点的辅方向：直方图的次峰值，能量超过主峰值能量的80%



旋转不变性


- 当图像发生旋转时，特征点的主方向相对于像素的梯度方向不变



- 将多幅待匹配的图像都旋转到令特征点方向为0的位置再匹配，使特征具有旋转不变性

4) 生成特征点的描述子(I)

- 将坐标轴方向旋转为特征点的方向
- 以特征点为中心取窗口，通过高斯加权增强特征点附近像素梯度方向信息的贡献
- 将窗口分为 4×4 的小块，每块中计算梯度方向直方图（取8个方向），计算梯度方向累加值，形成种子点



4) 生成特征点的描述子(II)

- 使用 $4*4$ 个种子点描述特征点，构成 $4*4*8=128$ 维特征向量
- 对描述子的进一步处理
 - 去除光照影响：将特征向量的长度归一化
 - 减弱扭曲影响（仿射变换）

SIFT特征对旋转、尺度缩放、亮度变化保持不变性，对视角变化、仿射变换、噪声也保持一定程度的稳定性

参考：https://blog.csdn.net/xiaowei_cqu/article/details/8069548

SIFT特征检测

➤ OpenCV3:

使用类**SIFT**检测SIFT特征

```
Ptr<SIFT> sift = SIFT ::create(...);  
sift->detectAndCompute(...);  
drawKeypoints(...); // 绘制特征
```

```
#include <opencv2/features2d.hpp>
```



SIFT特征检测

➤ OpenCV3: 使用类SIFT检测SIFT特征

`Ptr<SIFT> sift = SIFT ::create(...);`

```
static Ptr<SIFT> cv::SIFT::create ( int      nfeatures = 0,  
                                     int      nOctaveLayers = 3,  
                                     double   contrastThreshold =  
                                         0.04,  
                                     double   edgeThreshold = 10,  
                                     double   sigma = 1.6  
                                     )
```



SURF特征检测

➤ 针对SIFT特征计算复杂度较高的问题进行改进


➤ SIFT特征检测的步骤

SURF特征检测的改进

1. 检测尺度空间的极值点
2. 精确定位特征点
3. 设定特征点的方向参数
4. 生成特征点的描述子 (128维)



通过harr小波特征构造特征描述子 (64维)



通过harr小波特征设定特征点主方向

SURF特征检测

➤ OpenCV3:

使用类**SURF**检测SURF特征

```
Ptr<SURF> surf = SURF  
::creat(...);  
surf->detectAndCompute(...);  
drawKeypoints(...); // 绘制特征
```

```
#include  
<opencv2/xfeatures2d/nonfree.hpp>
```





SIFT特征
特征数：**403**
时间：**2.39s**



SURF特征
特征数：**321**
时间：**0.37s**

5.2.2 特征匹配

- 建立图像的特征点数据库
 - 每个特征点的数据结构包括：位置坐标、尺度、方向、特征向量（128/64维）
- 为新图像的每个特征点在数据库中逐个匹配
 - 根据特征向量的欧氏距离在数据库中寻找其最近邻和次近邻特征点
 - 若(最近邻距离/次近邻距离)小于某一阈值，则特征匹配成功

OpenCV3:

使用类BFMatcher实现特征的暴力匹配



左侧图**SURF**特征数：**321**

右侧图**SURF**特征数：**267**

5.3 HOG特征与行人检测

➤ HOG特征

- HOG(Histograms of Oriented Gradient, 梯度方向直方图)特征由Dalal等人在CVPR2005会议上提出
- 提取人体的外形信息和运动信息，形成丰富的特征集，用于行人目标的检测

➤ 主要内容


- 5.3.1 HOG特征
- 5.3.2 基于HOG特征的行人检测

Dalal N, Triggs B. **Histograms of oriented gradients for human detection**. CVPR 2005. 1: 886-893.

5.3.1 HOG特征

➤ HOG的基本思想

- 局部目标的外表和形状可以被局部梯度或边缘方向的分布很好的描述，即使不知道对应的梯度和边缘的位置
- 将图像分为细胞单元(cells)，计算细胞单元的梯度方向直方图
- 把细胞单元组合成块(block)并归一化，形成HOG描述子



5.3.1 HOG特征

➤ HOG的基本思想

- 局部目标的外表和形状可以被局部梯度或边缘方向的分布很好的描述，即使不知道对应的梯度和边缘的位置
- 将图像分为细胞单元(cells)，计算细胞单元的梯度方向直方图
- 把细胞单元组合成块(block)并归一化，形成HOG描述子

➤ HOG的生成步骤

1. 图像归一化
2. 计算图像梯度
3. 在细胞单元构建梯度直方图
4. 块内梯度直方图对比度归一化
5. 计算HOG特征描述子

1) 图像归一化

➤ 图像灰度化

- 将图像转换为灰度图像

➤ 图像归一化

- 采用Gamma校正法对输入图像进行颜色空间的标准化
- Gamma压缩:

$$I(x, y) = I(x, y)^{gamma}$$

取 $gamma = 1/2$

- Gamma校正可以有效降低图像局部的阴影和光照变化所造成的影响

2) 计算图像梯度

➤ 像素点 (x, y) 处的梯度

➤ 梯度幅值

$$m(x, y) = \sqrt{[f(x+1, y) - f(x-1, y)]^2 + [f(x, y+1) - f(x, y-1)]^2}$$

➤ 梯度方向


$$\theta(x, y) = \arctan\{[f(x, y+1) - f(x, y-1)] / [f(x+1, y) - f(x-1, y)]\}$$

➤ 无符号的梯度方向

$$\theta(x, y) = \begin{cases} \theta(x, y) + \pi & \theta(x, y) < 0 \\ \theta(x, y) & \text{others} \end{cases}$$

3) 在细胞单元构建梯度直方图

- 将图像分成若干个细胞单元 (cell)
- 为每个细胞单元构建**梯度方向直方图**，用梯度强度增加梯度方向影响，形成细胞单元的描述子
 - 统计梯度方向形成直方图，梯度幅值作为方向的权重
 - 直方图分成9个方向(bin)
 - 为了得到相对较小的梯度方向不变性，梯度强度对于每个bin的贡献用邻域bin的中心值进行插值得到




4) 块内梯度直方图对比度归一化


- 将多个细胞单元组合成一个块 (block)



矩形块



圆形块



中心环绕块



- 对块内的HOG特征向量进行归一化，形成HOG描述子


$$L2 - norm: \quad v \rightarrow v / \sqrt{\|v\|_2^2 + \varepsilon^2}$$

5) 计算HOG特征描述子

- 在图像中重叠选取块
- 将检测窗口中的所有块的HOG描述子组合，形成最终的HOG特征向量
- 行人的HOG特征
 - 样本图像大小：64*128像素
 - 细胞单元大小：8*8像素
 - 块内细胞单元数目：2*2
 - 块移动步长：8像素
 - 图像内总块数：7*15
 - HOG特征向量长度： $9*2*2*7*15=3780$




HOG举例



Original Image : 720 x 475

1、图像预处理



<https://www.learnopencv.com/histogram-of-oriented-gradients/>

HOG举例

2、计算图像梯度



X方向



y方向




梯度幅值

<https://www.learnopencv.com/histogram-of-oriented-gradients/>

HOG举例

3、在细胞单元构建梯度直方图



2	3	4	4	3	4	2	2
5	11	17	13	7	9	3	4
11	21	23	27	22	17	4	6
23	99	165	135	85	32	26	2
91	155	133	136	144	152	57	28
98	196	76	38	26	60	170	51
165	60	60	27	77	85	43	136
71	13	34	23	108	27	48	110

Gradient Magnitude



80	36	5	10	0	64	90	73
37	9	9	179	78	27	169	166
87	136	173	39	102	163	152	176
76	13	1	168	159	22	125	143
120	70	14	150	145	144	145	143
58	86	119	98	100	101	133	113
30	65	157	75	78	165	145	124
11	170	91	4	110	17	133	110

Gradient Direction

HOG举例





3、在细胞单元构建梯度直方图



<https://www.learnopencv.com/histogram-of-oriented-gradients/>

HOG举例



4、块内梯度直方图对比度归一化



<https://www.learnopencv.com/histogram-of-oriented-gradients/>

HOG举例

5、计算HOG特征描述子



HOG特征分析

➤ HOG的优点

- HOG表示的是**梯度/边缘**的结构特征，可以描述局部的形状信息
- **位置和方向的量化**一定程度上可以抑制平移和旋转的影响
- **局部区域归一化直方图**可以部分抵消光照变化带来的影响
- **分块分单元的处理方法**使得图像局部像素点之间的关系可以很好得到的表征

➤ HOG的缺点

- 描述子生成过程冗长，导致速度慢，实时性差
- 很难处理遮挡问题
- 由于梯度的性质，HOG对噪点相当敏感

5.3.2 基于HOG特征的行人检测*

➤ 训练分类器的思路

1. 收集正负样本

- 正样本2478个(1239幅行人图片以其左右翻转图)
- 负样本12180个(1218幅没有行人的图片中随机截取)

2. 提取正负样本的HOG特征

3. 利用正负样本进行SVM训练，形成初始SVM分类器



5.3.2 基于HOG特征的行人检测*

➤ 训练分类器的思路

1. 收集正负样本

➤ 正样本2478个

➤ 负样本12180个


2. 提取正负样本的HOG特征

3. 利用正负样本进行SVM训练，形成初始SVM分类器

4. 利用初始SVM分类器在负样本原图上进行行人检测，得到难例(hard example)

5. 将难例加入负样本集合，重新训练，形成最终SVM分类器


➤ **目标检测：** 检测窗口在图像中滑动，计算所有位置和尺度的HOG算子，用非极大值抑制实现目标检测



5.3.2 基于HOG特征的行人检测*

- OpenCV3:使用类HOGDescriptor计算HOG特征
 - HOGDescriptor::compute
计算图像的HOG特征向量
 - HOGDescriptor::detect: 进行物体检测
 - HOGDescriptor::detectMultiScale
用多尺度的窗口进行物体检测


```
#include <opencv2/objdetect.hpp>
```




5.4 基于Hough变换的线检测与圆检测

➤ 5.4.1 基于Hough变换的线检测

➤ 基本原理：点—线的对偶性质




XY平面



ab参数空间

5.4.1 基于Hough变换的直线检测

- 基本原理：点一线的对偶性质




在XY平面检测直线，转化为在参数空间检测交点

5.4.1 基于Hough变换的直线检测


- 使用直线的标准表示法

$$x \cos \theta + y \sin \theta = \rho$$

- 点—正弦曲线的对偶




XY平面




参数空间

5.4.1 基于Hough变换的直线检测

➤ 点—正弦曲线的对偶



XY平面



参数空间

若能在参数空间中确定交点，就实现了直线检测

Hough变换的性质

- 直角坐标系中的一个点映射到参数空间中为一条正弦曲线；
- 参数空间中的一个点对应直角坐标系中的一条直线；
- 直角坐标系中的共点线映射到参数空间中为一条曲线；
- 直角坐标系中的共线点映射到参数空间后为一个交于同一点的曲线簇

直线检测算法

算法： 基于Hough变换的直线检测

1. 将参数空间细分为 $m \times n$ 个累加单元，并设置累加器矩阵 Q
2. 将累加器矩阵 $Q(m \times n)$ 的初始值置为零
3. 对于XY平面上的点 (x_i, y_i) ，令 θ 等于 θ 轴上所有允许的细分值，计算对应的 ρ
4. 将得到的 ρ 值四舍五入为最接近 ρ 轴上的允许细分值
5. 在累加器矩阵 Q 中，找到所对应的单元，并将该单元的累加值加1
6. 重复3-5步直到处理完XY平面上的所有点，在累加器矩阵 Q 中，值最大单元对应的 θ 和 ρ 即为XY平面直线方程的参数

直线检测算法

➤ 细分讨论

- 直线检测的精度取决于两个参数细分值的大小
- 如果参数空间细分过粗，则参数的凝聚效果较差，找不出直线对应的准确参数
- 细分值也不能过小，会增大算法第3步的计算量



➤ 多条直线检测

- 在图像中检测R条直线，在累加器矩阵Q中取出前R个最大值单元
- 累加器单元中对应的 θ_k, ρ_k ($k = 1, 2, \dots, R$)，即为多条直线的参数

5.4.1 基于Hough变换的直线检测

➤ Matlab系列函数

- `hough`: 对二值图像进行Hough变换，形成累加器矩阵
- `houghpeaks`: 获取累加器矩阵的最大值，并记录位置
- `houghlines`: 基于Hough变换结果，检测直线




5.4.1 基于Hough变换的直线检测

➤ OpenCV3: HoughLines

- 利用Hough变换在二值图像中寻找直线
- 设定作为检出直线的最小累加值



threshold=78
检测出5条直线



threshold=60
检测出35条直线

5.4.1 基于Hough变换的直线检测

➤ OpenCV3: HoughLinesP

- 利用概率Hough变换在二值图像中寻找线段
- 不需要逐行扫描图像，而是随机挑选像素点




HoughLines
检测结果



HoughLinesP
检测结果

5.4.2 基于Hough变换的圆检测

- 圆的表达式: $(x-a)^2 + (y-b)^2 = r^2$
- 半径已知
 - 二维参数空间 (a, b)
 - XY平面的点对应参数空间的一个圆; XY平面同一个圆上的点, 在参数空间对应的圆过同一点 (a, b)
- 半径未知
 - 三维参数空间 (a, b, r)
 - XY平面的点对应参数空间中每一半径下的一个圆 (圆锥)



5.4.2 基于Hough变换的圆检测


➤ OpenCV3: HoughCircles

- 利用Hough变换在二值图像中寻找圆
- 建议在圆检测之前，对原图像进行平滑从而减少误检测
- 参数包括累加器分辨率、两个圆之间最短距离、Canny 阈值、累加器阈值、极大极小半径



5.5 图像特征检测在生物、显微视觉中的应用

- 基于SIFT特征的显微图像拼接
- 基于HOG特征的斑马鱼个体识别
- 基于Hough直线检测获取微夹钳运行性能




1、基于SIFT特征的显微图像拼接



➤ 图像匹配策略

- 图像重叠区信息丰富(低倍物镜): 基于SIFT特征匹配图像



1、基于SIFT特征的显微图像拼接


➤ 图像匹配策略

- 图像重叠区信息丰富(低倍物镜): 基于SIFT特征匹配图像
- 图像重叠区信息较少(高倍物镜): 基于灰度的图像匹配
 - 基于SIFT特征获得当前倍率图像与低倍率图像的关系, 获得区域搜索范围
 - 在缩小的搜索范围内, 进行基于区域的图像匹配

1、基于SIFT特征的显微图像拼接

➤ 图像匹配策略

- 图像重叠区信息丰富(低倍物镜): 基于SIFT特征匹配图像
- 图像重叠区信息较少(高倍物镜): 基于灰度的图像匹配




1、基于SIFT特征的显微图像拼接

➤ 图像匹配策略

- 图像重叠区信息丰富(低倍物镜): 基于SIFT特征匹配图像
- 图像重叠区信息较少(高倍物镜): 基于灰度的图像匹配



➤ 图像融合方法: 多波段图像融合




2、基于HOG特征的斑马鱼个体识别



➤ 斑马鱼背部纹理的HOG特征提取




尾部存在较大弯曲，
feature map杂乱无序



2、基于HOG特征的斑马鱼个体识别


➤ 斑马鱼背部纹理的HOG特征提取



2、基于HOG特征的斑马鱼个体识别



➤ 斑马鱼背部纹理的HOG特征提取





- 螺旋输出一定数量的、标记为1的Block，得到最终改进的HOG特征
- 保证Feature map中包含较多的背部纹理，较少的背景信息
- 减小特征向量空间，降低分类器计算代价，保证不同图像样本间特征序列的一致性

2、基于HOG特征的斑马鱼个体识别



➤ 斑马鱼个体识别



♥ 训练样本类别

♥ 测试样本类别

♥ 预测概率

$$P = \begin{matrix} & \begin{matrix} T_1 & T_2 & \dots & T_j & \dots & T_N \end{matrix} \\ \begin{matrix} T_1' \\ T_2' \\ \vdots \\ T_i' \\ \vdots \\ T_N' \end{matrix} & \begin{pmatrix} p_{11} & p_{12} & \dots & p_{1j} & \dots & p_{1N} \\ p_{21} & p_{22} & \dots & p_{2j} & \dots & p_{2N} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ p_{i1} & p_{i2} & \dots & p_{ij} & \dots & p_{iN} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ p_{N1} & p_{N2} & \dots & p_{Nj} & \dots & p_{NN} \end{pmatrix} \end{matrix} \subset R^{N \times N}$$

♥ 概率匹配 $\max(\sum_{ij}^N P_{ij})$

$st. P_{im}, P_{in}, m \neq n;$

$P_{hj}, P_{kj}, h \neq k; i \neq j;$


♥ 目标预测标签 $L_i = j$

$st. p_{ij} > \frac{1}{N}; 1 < i < N; 1 < j < N$


2、基于HOG特征的斑马鱼个体识别



➤ 斑马鱼多目标跟踪：轨迹段的分类与匹配



- 选取初始轨迹段训练分类器：交叉前后引入HOG
- 交叉前后轨迹段组A/B
- 选择A组轨迹段为训练样本： $\min(NF)_A > \min(NF)_B$
- 初始轨迹段加长，丰富样本



- 全局轨迹段的分类与匹配
- 属于3个目标的9个轨迹段等待拼接
- 选择包含较长的最短轨迹段的一组为训练组
- 初始轨迹段加长，丰富样本

2、基于HOG特征的斑马鱼个体识别




➤ 斑马鱼多目标跟踪



2、基于HOG特征的斑马鱼个体识别



➤ 斑马鱼多目标跟踪




3、基于Hough直线检测获取微夹钳运行性能

➤ 微夹钳的运动



3、基于Hough直线检测获取微夹钳运行性能

- 从录像获得图像序列，每秒26帧，共获得494张图像
- 分别获取钳臂前、中、后三个位置的运动轨迹



3、基于Hough直线检测获取微夹钳运行性能

- 在图像中获取钳臂图像，完成图像灰度化



钳臂打开



钳臂闭合

- 边缘检测：使用canny和prewitt两种算子获得二值图像




钳臂打开




钳臂闭合

3、基于Hough直线检测获取微夹钳运行性能

- 通过Hough变换检测直线




钳臂打开



钳臂闭合

- 检测结果


- 钳臂后部位移1.65像素
- 钳臂中部位移2.75像素
- 钳臂前部位移4个像素



总结



传统特征检测



The End



机器人与信息自动化研究所

Institute of Robotics & Automatic Information System



南開大學

Nankai University