

机器视觉深度学习部分

PPT7——图像检测

AlexNet

核心特点：

- ReLU激活函数：替代传统的sigmoid/tanh，缓解梯度消失问题，加速训练。
- GPU并行训练：利用双GPU并行计算，提升训练效率。
- 过拟合处理：
 - Dropout：随机丢弃部分神经元，增强模型泛化能力。
 - 数据增强：通过裁剪、翻转、平移等操作扩充数据。
 - 省流：
使用ReLU作为激活函数，从sigmoid/tanh到Relu；
过拟合处理：
使用GPU并行。

VGGNet

- 小卷积核堆叠：全部使用 3×3 卷积核（替代大卷积核），减少参数量并增加非线性。
- 深度扩展：通过增加卷积层数量（如VGG16有16层，VGG19有19层）提升性能。
- 结构简洁：模块化设计（多个 3×3 卷积 + 最大池化），便于迁移学习。
- 高内存消耗：因全连接层参数量大，模型体积较大。

GoogLeNet

- Inception模块：
 - 并行使用不同尺寸的卷积核（ 1×1 、 3×3 、 5×5 ）和池化，融合多尺度特征。
 - 通过 1×1 卷积降维，减少计算量（如从854M FLOPs降至358M）。
- 辅助分类器：在中间层添加辅助输出，缓解梯度消失问题。
- 轻量化设计：参数量仅为AlexNet的1/12，VGG的1/27，但性能更优。

ResNet

- 残差连接（Residual Block）：
 - 引入恒等映射（shortcut connection），使深层网络易于训练。
 - 公式： $F(x)+x$ ，避免梯度消失。
- 网络深度：支持极深网络（如ResNet152），性能随深度提升。

总结

- AlexNet 使用ReLU激活函数、引入dropout处理过拟合
- VGGNet 小卷积核（3*3）的使用
- GoogLeNet 引入Inception结构
- ResNet 引入残差学习

PPT8——目标检测与图像分割

目标：定位+分类

Two-Stage（两阶段）

R-CNN: Selective Search提取候选框 → CNN提取特征 → SVM分类 + BBox回归。

缺点：计算慢（2000个ROI独立提特征）、流程分裂。

Fast R-CNN: 共享卷积层 + ROI Pooling → 端到端训练（分类+回归联合损失）

Faster R-CNN: 引入RPN（Region Proposal Network）生成候选框，与检测网络共享卷积层。

One-Stage（单阶段）

YOLO: 将图像划分为 $s \times s$ 网格，每个网格直接预测边界框和类别（实时性强）。

SSD: 结合YOLO的网格思想和Faster R-CNN的Anchor机制，在多尺度特征图上检测目标。

图像分割

语义分割：对每个像素分类（仅区分类别，不区分个体）。

实例分割：对每个目标实例进行像素级分割（区分同类不同个体）。

FCN（全卷积网络）：

- 用卷积替代全连接层，支持任意尺寸输入。
- 关键操作：上采样（反卷积/反池化）恢复分辨率。

UNet：

- 编解码结构：下采样（编码）→ 上采样（解码） + 跳跃连接（融合浅层细节）。